openJiuwen 创意大赛提交模板



PromptForge （提示词锻造台） | Coding 赛道 | deforoout 队

创意名称 PromptForge （提示词锻造台）

创意描述（必填，<500 字）

痛点： AI 开发每天面对大量“一句话需求”，但提示词质量参差、单模型自评不可靠、方案返工成本高。

做法： PromptForge 是 AI 开发者的“提示词编译器 + 评审会”：把关键词编译成含验收标准的任务规格，生成 2~4 个“假设不同”的候选提示词，调用多个模型真实执行并自动跑测试，采集测试通过率、lint、耗时与费用等证据，再由异构评委盲评，用 TOPSIS/Pareto 选出可解释的最优方案，并给出成本账单。

Demo v0.1： 聚焦 Coding 场景——给已有 FastAPI 待办 API 加“标签筛选 + 分页” → 两份候选实现 → 真跑 6 条 pytest → 证据对比 → 推荐方案。我们不做“更会聊天的提示词工具”，而是让“选哪个方案”第一次有证据、可复现、可算账。

所属主题（必填）

Coding 赛道

应用场景（必填）

用户： 独立开发者、高校学生、2~20 人研发团队；接到一句话需求、需要给现有项目加功能 / 修 Bug/ 做方案选型的人。

场景： 先用 PromptForge 把“给待办列表加标签筛选和分页”变成 6 条可执行验收标准；多个模型各写一版 app/main.py；系统真实跑 pytest，按证据选方案，并给出成本账单。

价值： 对个人，降低与 AI 协作的提示词门槛；对团队，把方案评审从“拍脑袋”变成“看数据”，减少返工轮数与 token 浪费；对 AI 开发流程，让“选方案”第一次可复现、可审计。

openJiuwen AI 生成

创意方案构想

方案详情（必填）

- **需求编译：**一句话 → SRD （目标 / 约束 /6 条可执行验收标准）
- **多候选生成：** 2~4 个“假设不同”的提示词（如先写测试 vs 直接实现）
- **真实执行：**多模型生成代码 → 沙箱跑 pytest/lint ， 采集证据包
- **异构评审：** 2~3 个不同模型盲评 + 规则校验，输出一致性 / 置信说明
- **决策交付：**硬约束过滤 → TOPSIS/Pareto → 决策卡（推荐 / 证据 / 费用）
- **可复现：** Prompt DAG 记录来源、证据与费用，可回放

技术依赖（可选）

- **openJiuwen WorkSwarm / AgentOS：**任务规划、 Skills 、 Channel
- **Agent Framework / Agent System Service：**多 Agent 协同、安全沙箱
- **华为云 MaaS：** glm-5.2 / openpangu-2.0-flash （ OpenAI 兼容）
- **执行栈：** Python 3.11 + pytest + Git ； v0.2 复用 Streamlit 看板
- **合规：**仅官方 API / 本地部署；演示数据脱敏

方案优势（可选）

- **证据而非感觉：**测试通过率、 lint 、耗时、费用都是真实执行结果
- **多假设而非同义改写：**候选对应不同架构 / 验证策略，差异有信息量
- **可解释：**每个评分指得到具体证据；分差在置信区间内不强行排序
- **成本可控：** Token Ledger + 剪枝 / 早停，预算内给当前最优

打磨验证 / 预期 Demo 形式

- **预期 Demo：** CLI 最小闭环 + 一页对比看板（测试红绿 / 证据 / 费用）
- **11-10 前：** 60 秒真实运行录屏，用于创意 PPT “项目运行”
- **12 月：** 3 分钟视频 + 现场演示；固定任务集 A/B 对照
- **资源：** 3 个模型 API 、 1 台开发机、 Docker 沙箱
- **兜底：**缓存回放 / 本地模型 / 录屏，保证现场不翻车

DEMO 与关键用户路径（Demo v0.1 规划）



示意图： Demo v0.1 规划；图中红绿与分数为预期演示剧情，实测后替换

关键用户路径

- ① **触发：** CLI 或网页输入一句话需求
- ② **输入：** 关键词 + 可选仓库 / 约束 / 目标模型
- ③ **回显：** SRD + 6 条验收标准，用户确认或修改
- ④ **执行：** 2 候选并行生成 + 沙箱真跑 pytest/lint
- ⑤ **结果：** 证据看板：红绿、失败用例、耗时、 token 费用
- ⑥ **决策：** 推荐 + 证据链 + 次优备选 + 成本账单
- ⑦ **回放：** 证据包与 Prompt DAG 可复现、可审计

- **Demo 形态：** v0.1 命令行； v0.2 加 Streamlit 对比看板

Demo v0.1 交付物： CLI 命令 · evidence.json · decision.md · 60 秒真实录屏 · 离线回放包

数据规则： 所有红绿 / 分数 / 费用以真实执行日志为准；未实测内容一律标注“待实测”，不写进结论。

代码仓库： https://github.com/dissill/LLM

附：赛题方向详细参考

01 办公赛道

核 心 价 值

让智能体成为你的办公助手。围绕会议纪要、文档处理、流程自动化、数据报表、知识管理等场景，打造高效、精准、可靠的生产力工具

示 意 方 向

- 会议纪要 · 自动记录、提炼、分发会议要点
- 文档处理 · 智能起草、审阅、格式化文档
- 流程自动化 · 审批、归档、通知自动执行
- 协同办公 · 多人协作、任务分配、进度跟踪
- 数据报表 · 采集、分析、生成可视化报表
- 知识管理 · 企业知识库构建与智能检索

02 Coding 赛道

核 心 价 值

让智能体成为你的开发搭档。覆盖代码生成、审查、 Bug 修复、自动化测试、项目脚手架等全研发链路，提升开发效率与代码质量

示 意 方 向

- 代码生成 · 根据需求自动生成代码片段
- 代码审查 · 自动 PR 审查，识别潜在问题
- Bug 修复 · 定位根因并生成修复方案
- 自动化测试 · 生成测试用例并执行验证
- 项目脚手架 · 快速搭建项目结构与环境
- 代码重构 · 智能优化代码结构与性能

03 科研赛道

核 心 价 值

让智能体成为你的科研伙伴。从文献检索、实验设计到数据分析、论文写作，全方位辅助科研全流程，激发创新灵感

示 意 方 向

- 文献检索 · 智能搜索、筛选、综述文献
- 实验设计 · 辅助实验方案设计与优化
- 数据分析 · 自动清洗、统计与可视化
- 科研写作 · 辅助论文撰写与引用管理
- 创新灵感 · 跨领域知识关联与思路启发
- 学术协作 · 多人合著、版本管理、同行评审

04 设备互联赛道

核 心 价 值

让智能体突破数字边界。跟硬件生态结合，实现人机 / 机机联动，将智能体的眼、手、脚实体化，打造虚实融合新体验

示 意 方 向

- 人机联动 · 语音、手势、眼动多模态交互
- 机机联动 · 跨设备协同、任务自动流转
- 智能体眼 · 摄像头 / 传感器感知环境
- 智能体手 · 机械臂 / 机器人执行物理操作
- 智能体脚 · 移动平台实现空间自主移动
- 虚实融合 · 数字孪生、 AR/VR 联动体验

*** 示意方向仅做场景参考，不限定大家的想象力**

附：评分标准

标准	描述	分数定位
项目运行	**所有团队都必须制作真正的原型**	1： 重大问题或项目未运行
		2： 小错误
		3： 可运行
		4： 完美执行
		5： 卓越且安全的架构
创新与创造力（创造性）	**致力于寻求 AI 智能体界限的突破性想法**	1： 非原创的想法
		2： 以前尝试过的想法
		3： 有些新意的想法
		4： 新颖的概念或创造性的解决方案
		5： 具有出色实施效果的突破性想法
对现实世界的影响（价值性）	**有可能对用户或垂直领域产生重大影响的工作**	1： 实际用途有限
		2： 具有未来潜力，但当前没有影响
		3： 对当前有一定的影响
		4： 解决了重大需求
		5： 具有改变生活的潜力，以创新方式解决关键问题
主题一致性（相关性）	**与本次主题相一致**	1： 与主题几乎不相关
		2： 与主题有表面上的联系
		3： 和主题一致
		4： 清晰而有意义地体现了主题
		5： 完美的体现和提升了主题，展示了先进的 AI 能力在现实场景中的创新应用

Demo 分镜： 60 秒创意版 / 3 分钟 DEMO 版

60 秒创意版（11-10 前）

- **0–5s** 黑底白字： “AI 写的代码，你敢直接合并吗？”
- **5–15s** CLI 输入一句话需求（FastAPI 待办：标签筛选 + 分页）
- **15–30s** 回显 6 条验收标准 → 两候选并行生成
- **30–45s** 真跑 pytest： A 红 4/6 （A4/A6 失败）、 B 绿 6/6 （待实测）
- **45–55s** 决策卡：推荐 B，理由指到测试输出；费用见账单
- **55–60s** Slogan： PromptForge，一次选对，少返工

3 分钟 DEMO 版（12-27）

- **0:00–0:20 问题：** 提示词方差大、单模型自评不可靠、返工贵
- **0:20–0:50 输入：** 一句话需求 → SRD 6 条验收标准
- **0:50–1:40 执行：** 两候选各写一版 FastAPI 接口，沙箱真跑，测试红绿滚动
- **1:40–2:20 证据：** 失败用例（A4 组合 /A6 参数）、耗时、费用、评委分
- **2:20–2:45 决策：** 推荐 + 证据链 + 次优 + 成本账单
- **2:45–3:00 收尾：** 可复现、可扩展（WorkSwarm 集群）

拍摄要点

- 不剪掉候选 A 失败画面：失败用例名必须出现在屏幕上
- 费用 / 耗时来自真实 token 统计，不能手填
- 录屏分辨率 1080p，命令行字号 ≥ 16pt
- 提前准备离线回放，网络故障可直接切

兜底方案

- 模型 API 失败 → 缓存上一次真实结果回放
- 沙箱异常 → 本机 subprocess + 固定依赖锁
- 断网 → 本地录屏 + 证据回放，不假装实时
- 双备份：主演示机 + 备用机，提前彩排 ≥ 2 次

真实证据、指标与兜底（不造假）

Demo 必须展示的真实证据（v0.1）

- **pytest 通过率：** 6 条用例逐条红绿，失败用例名可见
- **lint / 编译：** ruff + py_compile，作为质量门槛
- **执行耗时：** 沙箱墙钟时间，方案间可比
- **token 费用：** 真实 usage × 价格快照，写入账单
- **评委分：** 1 个异构模型盲评（v0.1），仅用于解释

兜底与合规

- 模型调用：仅官方 API / 云服务 / 本地部署
- API 限流 / 超时：指数退避 + 备用模型
- 沙箱失败：本机 subprocess + 依赖锁
- 现场断网：缓存证据 + 录屏回放
- 演示数据脱敏；不泄露密钥 / 内部地址

对外口径（数据规则）

- 只引用真实日志；演示前预置数据必须标注
- “预期剧情 / 预期分数”一律标“待实测”
- 不剪掉失败画面；不修改测试用例
- 证据包 + 原始日志可复算，随仓库提交

DoD （Demo v0.1 完成标准）

- 一条命令跑通：需求 → 2 候选 → 测试 → 证据 → 决策
- 总耗时 ≤ 90 秒（超时则缓存回放）
- 输出 evidence.json + decision.md，可复算
- 60 秒真实录屏 + 离线可回放

代码仓库： https://github.com/dissill/LLM | 团队： deforoout | 数据规则：真实日志为准，未实测不写结论

Thank you.

